

Series de tiempo ARIMA y SARIMA:

Estudio del comportamiento mensual d la inflación en Argentina desde 1970 a 2024

William Gutierrez

Yza Toro

Michelle Curiel

Paola Puentes

Gabriel Pulido

Elías González

Prof. Laura Castillo

Julio del 2024

Índice

Índice	2
Análisis de series de tiempo estocástica	3
Modelo general ARIMA(p,q,d)	3
Usamos medias móviles para suavizar el componente estacional	4
Descripción de la gráfica de suavizamiento con medias móviles	5
Análisis Económico	5
Descomposición de la serie de tiempo	6
Estacionariedad	9
Autocorrelación simple	10
Serie de tiempo diferenciadas, es	13
Estacionariedad	14
Autocorrelación de la serie diferenciada	15
Modelo ARIMA	16
Interpretación del Modelo ARIMA (5,1,4)	17
Coeficientes del modelo	17
Coeficientes AR modelo (5,1,4) (Autorregresivos)	17
Coeficientes MA modelo (5,1,4) (Media Móvil)	18
Interpretación del Modelo ARIMA (2,0,1)	19
Coeficientes AR modelo ARIMA (2,0,1) (Autorregresivos)	19
Coeficiente MA modelo ARIMA (2,0,1) (Media Móvil)	19
Interpretación económica	20
Predicción	20
Análisis del Gráfico y Predicción Económica	22
Comportamiento Histórico	22
Predicción a Futuro	23
Interpretación Económica	23
Validación	24
Prueba de Ljung-Box	25
Prueba de Shapiro-Wilk	25
Resultados e Interpretación:	26
Conclusión de las pruebas	26
Resumen de la Interpretación	26

Análisis de series de tiempo estocástica

El motivo de la introducción de los modelos ARIMA nace del hecho de que no se puede trabajar con una serie temporal no estacionaria. Se dice que una serie es estacionaria cuando su media, varianza y auto covarianza son invariantes en el tiempo. La mayoría de series temporales económicas no son estacionarias, pero diferenciándolas un número determinado de veces la serie original se transforma en estacionaria, con lo cual ya se podría aplicar la metodología de los modelos ARIMA. A continuación, se mostrará la serie de tiempo “**Inflación de argentina**” en la cual se mostrará las sucesiones de datos mensuales desde el año 1970 hasta la actualidad.

Modelo general ARIMA(p,q,d)

MODELO GENERAL ARIMA(p,q,d)

A continuación, se buscará el modelo que mejor se ajuste a la serie de datos.

Introducción de los datos

```
#library(ggplot2)
##library(forecast)
##library(tseries)
##library(readxl)
##library(lmtest)

##datos <- read_excel("C:/Users/MARK/Desktop/Econometria II/datos de series de tiempo argentina.xlsx")

##datos.ts= ts(datos)
```

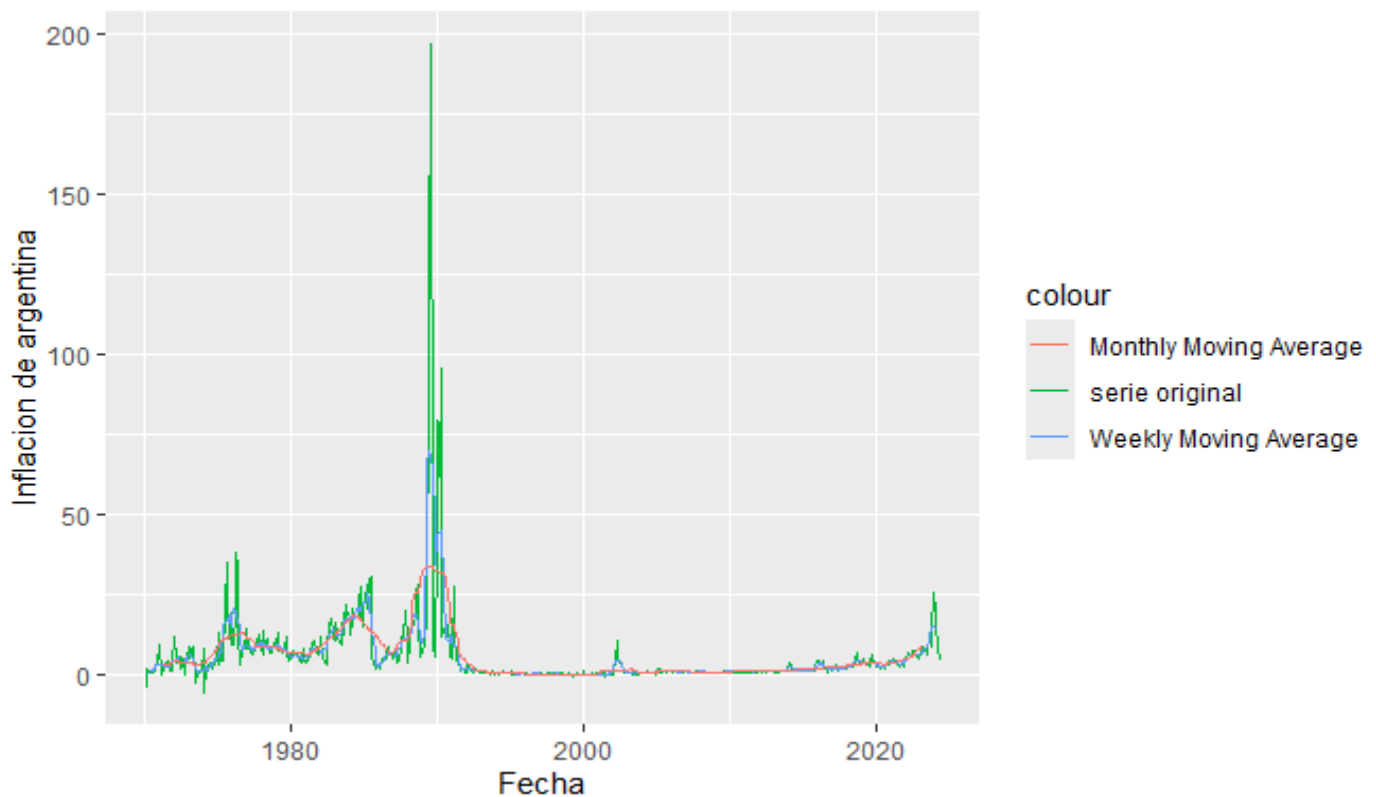
Trazamos la serie de tiempo con ggplot

```
ggplot() +
  geom_line(data = datos, aes(x = Fecha , y = Valor)) + ylab('Inflacion de argentina')
```

Usamos medias móviles para suavizar el componente estacional

```
datos$Valor.ma = ma(datos$Valor
, order=7)
datos$Valor30.ma = ma(datos$Valor, order=30)

ggplot() +
  geom_line(data = datos, aes(x = Fecha, y = Valor, colour = "serie original")) +
  geom_line(data = datos, aes(x = Fecha, y = Valor.ma, colour = "Weekly Moving Average"))
+
  geom_line(data = datos, aes(x = Fecha, y = Valor30.ma, colour = "Monthly Moving Average"))
) +
  ylab('Inflacion de argentina')
```



Descripción de la gráfica de suavizamiento con medias móviles

- **Serie Original:** Representada por una línea de color que muestra los valores mensuales de inflación.
- **Media Móvil Semanal (Weekly Moving Average):** Representada por una línea que suaviza los datos usando un promedio móvil de 7 periodos (aproximadamente una semana).
- **Media Móvil Mensual (Monthly Moving Average):** Representada por una línea que suaviza los datos usando un promedio móvil de 30 periodos (aproximadamente un mes).

Análisis Económico

1. Serie Original

La serie original muestra la volatilidad y fluctuaciones en la inflación mensual. Estos movimientos pueden ser atribuidos a diversos factores económicos, políticos y externos que afectan la economía argentina.

2. Media Móvil Semanal

La media móvil de 7 periodos suaviza la serie original eliminando algunas de las fluctuaciones diarias más extremas, permitiendo una visualización más clara de las tendencias subyacentes a corto plazo.

Esta suavización puede ayudar a identificar patrones de comportamiento semanal y detectar cambios rápidos en la tendencia de la inflación.

3. Media Móvil Mensual

La media móvil de 30 periodos proporciona una vista aún más suavizada de la serie temporal, eliminando gran parte del ruido de corto plazo y resaltando tendencias y ciclos a más largo plazo.


Descomposición de la serie de tiempo

La descomposición de una serie de tiempo en sus componentes se realiza con el objetivo de identificar y separar los patrones subyacentes. En este caso, se han descompuesto los datos de inflación en Argentina en cuatro componentes:

1. **Serie Original (data):** Representa los valores originales de la serie de tiempo de la inflación mensual.
2. **Tendencia (trend):** Muestra la evolución a largo plazo de la serie de tiempo, eliminando las fluctuaciones estacionales y aleatorias.
3. **Estacionalidad (seasonal):** Refleja los patrones repetitivos en la serie de tiempo con una periodicidad específica (por ejemplo, mensual en este caso).
4. **Irregularidad (remainder):** Representa las fluctuaciones aleatorias que no se explican por la tendencia o la estacionalidad.

Primero, calculamos el componente estacional del uso de datos stl (). A continuación, hallamos el componente estacional de la serie mediante suavizado y ajusta la serie original restando la estacionalidad.

```
##count_ma = ts(na.omit(datos$Valor30.ma), frequency=30)
##decomp = stl(count_ma, s.window="periodic")
##deseasonal_inf <- seasadj(decomp)
##plot(decomp)
```



```
# Los datos están en la segunda columna:
datos <- datos[[2]]

# Convertir los datos a un objeto de serie de tiempo
datos.ts <- ts(datos, start = c(1970, 7), frequency = 12)

# Verifica la longitud de la serie de tiempo


length(datos.ts)

## [1] 653
```

```
# Descomponer la serie de tiempo
datos_decomp <- decompose(datos.ts)

# Dividir la ventana gráfica en una matriz de 2 filas y 2 columnas
par(mfrow = c(2, 2))

# Graficar los componentes descompuestos de la serie de tiempo
plot(datos_decomp$x, main = "Serie de tiempo - Original", col = "black", ylab = "Valores")
plot(datos_decomp$trend, main = "Tendencia", col = "blue", ylab = "Valores")
plot(datos_decomp$seasonal, main = "Estacionalidad", col = "red", ylab = "Valores")
plot(datos_decomp$random, main = "Irregularidad", col = "green", ylab = "Valores")
```



La eliminación de la estacionalidad se realiza para obtener una serie más adecuada para el modelado ARIMA. Esto se logra restando el componente estacional de la serie original.

Económicamente, la estacionalidad en la inflación puede reflejar patrones recurrentes que ocurren en ciertos períodos del año debido a factores como políticas fiscales expansivas como se puede detectar a final del año 1989, el promedio de inflación de Argentina fue de 46,5%, por lo tanto, Argentina para este año estaba aproximándose a una espiral hiperinflacionaria en el Gobierno de transición de Raúl Alfonsín coincidiendo ya entrando la nueva década, en 1989-1990 con un cambio de Gobierno en Argentina de la mano de la primer Gobierno de Carlos Menem.

Si tiene una tasa del 50% mensual en promedio, se establece que el país tiene una hiperinflación, debemos señalar, que este consenso se debe al trabajo del economista estadounidense Philip Cagan. En su estudio seminal titulado "*The Monetary Dynamics of Hyperinflation*," publicado en 1956, Cagan analizó varios episodios de hiperinflación y estableció este umbral del 50% mensual como criterio para definir una situación de hiperinflación.

Pero, debemos señalar que la estacionalidad de la inflación alta no solo se explica por una política monetaria expansiva, que financia el déficit del gasto público (monetización del déficit), también se puede deber a la producción agrícola, cambios en la demanda estacional, etc. Al eliminar este componente, podemos enfocarnos mejor en los cambios subyacentes de largo plazo y en las fluctuaciones aleatorias que no están relacionadas con estos patrones repetitivos.

Econométricamente, eliminar la estacionalidad es esencial para la correcta identificación y estimación de modelos ARIMA, ya que estos modelos asumen que la serie es estacionaria. La serie estacionaria tiene media, varianza y auto covarianza constantes en el tiempo, lo cual es una condición necesaria para la aplicación de modelos ARIMA. La prueba de Dickey-Fuller aumentada (ADF) confirma la estacionariedad de la serie ajustada.

Estacionariedad

La instalación de un modelo ARIMA requiere que la serie sea estacionaria. Se dice que una serie es estacionaria cuando su media, varianza y auto covarianza son invariantes en el tiempo.

Esta suposición tiene un sentido intuitivo:

Dado que ARIMA usa retardos previos de series para modelar su comportamiento

```
adf.test(count_ma, alternative = "stationary")  
  
##  
## Augmented Dickey-Fuller Test  
##  
## data: count_ma  
## Dickey-Fuller = -3.6555, Lag order = 8, p-value = 0.02736  
## alternative hypothesis: stationary
```

Contraste de hipótesis:

H0: No estacionaria **H1:** Estacionaria


Tras realizar la prueba aumentada de Dickey-Fuller (ADF), obtenemos un p-valor = 0.02 Como el p-valor < 0.05, rechazamos H0. Podemos concluir que nuestra serie temporal es estacionaria.

Autocorrelación simple


La función de autocorrelación (ACF) mide la correlación entre una serie de tiempo y sus valores retrasados. Para determinar el valor de q en un modelo ARIMA, se puede mirar el gráfico ACF y buscar el primer retraso que tiene una correlación significativa (es decir en donde se sobrepasen las líneas punteadas. *Este valor corresponderá a q (MA=1 O 2 o 3 o...q valor)*

Las PACF proporcionan la relación directa existente entre observaciones separadas por k retardos, la función de autocorrelación parcial (PACF) mide la correlación entre una serie de tiempo y sus valores retrasados, pero teniendo en cuenta la influencia de los valores intermedios.

```
Acf(count_ma, main='')
```



```
Pacf(count_ma, main='')
```




Serie de tiempo diferenciadas, es

#serie estacionaria

```
count_d1 = diff(deseasonal_inf, differences = 1)
```

```
plot(count_d1)
```




#decomposicion

```
decomp2 = stl(count_d1, s.window="periodic")
```

```
deseasonal_inf2 <- seasadj(decomp2)
```

```
plot(decomp2)
```



Estacionariedad

```
adf.test(count_d1, alternative = "stationary")
```

```
## Warning in adf.test(count_d1, alternative = "stationary"): p-value smaller than
## printed p-value
```

```
##
```

```
## Augmented Dickey-Fuller Test
```

```
##
```

```
## data: count_d1
```

```
## Dickey-Fuller = -4.4557, Lag order = 8, p-value = 0.01
```

```
## alternative hypothesis: stationary
```


Contraste de hipótesis:

H0: No estacionaria **H1:** Estacionaria


Tras realizar la prueba aumentada de Dickey-Fuller (ADF), obtenemos un p-valor = 0.01. Como el p-valor < 0.05, rechazamos H0. Podemos concluir que nuestra serie temporal es estacionaria.

Autocorrelación de la serie diferenciada

```
Acf(count_d1, main="")
```



```
Pacf(count_d1, main='')
```



Modelo ARIMA

```
#serie sin diferenciar
auto.arima(deseasonal_inf, seasonal=FALSE)

## Series: deseasonal_inf
## ARIMA(5,1,4)
##
## Coefficients:
##          ar1      ar2      ar3      ar4      ar5      ma1      ma2      ma3
##          0.5751 -0.0991  0.7494 -0.6233  0.2746  1.1146  0.3845 -0.5818
## s.e.    0.0589  0.0455  0.0325  0.0496  0.0451  0.0512  0.0866  0.0843
##          ma4
##          -0.6538
## s.e.    0.0500
##
## sigma^2 = 0.03799: log likelihood = 136.29
## AIC=-252.57  AICc=-252.21  BIC=-208.24

#serie diferenciar
auto.arima(deseasonal_inf2, seasonal=FALSE)

## Series: deseasonal_inf2
## ARIMA(2,0,1) with zero mean
##
## Coefficients:
##          ar1      ar2      ma1
```



```
##      0.7528 -0.0679  0.9284
## s.e.  0.0460  0.0459  0.0248
##
## sigma^2 = 0.04205:  log likelihood = 102.54
## AIC=-197.08   AICc=-197.01   BIC=-179.35
```

Por lo tanto, basados en los criterios de información, correlogramas y además por parsimonia, elegimos la serie ARIMA (5,1,4).

Interpretación del Modelo ARIMA (5,1,4)

Este modelo tiene la forma ARIMA(p,d,q) donde:

- $p=5$ indica que el modelo incluye 5 términos autorregresivos (AR).
- $d=1$ indica que la serie de tiempo ha sido diferenciada una vez para hacerla estacionaria.
- $q=4$ indica que el modelo incluye 4 términos de media móvil (MA).

Coefficientes del modelo

Coefficientes AR modelo (5,1,4) (Autorregresivos)

1. $AR(1) = 0.5751$

Este coeficiente indica que un aumento en la inflación del mes anterior (t-1) está asociado con un aumento de aproximadamente el 57.51% en la inflación del mes actual. Esto sugiere una inercia significativa en la inflación: si la inflación fue alta el mes pasado, es probable que siga siendo alta este mes.

2. $AR(2) = -0.0991$

Un valor negativo sugiere que un aumento en la inflación dos meses antes (t-2) está asociado con una disminución del 9.91% en la inflación del mes actual. Esto implica una corrección parcial en el segundo mes.

3. $AR(3) = 0.7494$

Este coeficiente positivo sugiere que un aumento en la inflación tres meses antes (t-3) está asociado con un aumento del 74.94% en la inflación del mes actual. Indica una fuerte persistencia a más largo plazo en los valores de inflación pasados.

4. **AR(4) = -0.6233**

Un valor negativo sugiere que un aumento en la inflación cuatro meses antes (t-4) está asociado con una disminución del 62.33% en la inflación del mes actual. Este patrón indica una oscilación cíclica en los valores de inflación.

5. **AR(5) = 0.2746**

Este coeficiente positivo indica que un aumento en la inflación cinco meses antes (t-5) está asociado con un aumento del 27.46% en la inflación del mes actual. Aunque más pequeño que los coeficientes anteriores, aún sugiere una influencia persistente de los valores de inflación pasados.

Coefficientes MA modelo (5,1,4) (Media Móvil)

1. **MA(1) = 1.1146**

Este coeficiente indica que un shock (o error) en la inflación del mes anterior (t-1) está asociado con un aumento del 111.46% en la inflación del mes actual. Esto sugiere que los shocks tienen un efecto amplificado y persistente en la inflación.

2. **MA(2) = 0.3845**

Este coeficiente positivo sugiere que un shock en la inflación dos meses antes (t-2) está asociado con un aumento del 38.45% en la inflación del mes actual. Los efectos de los shocks aún son significativos pero menores que el primer término.

3. **MA(3) = -0.5818**

Un valor negativo sugiere que un shock en la inflación tres meses antes (t-3) está asociado con una disminución del 58.18% en la inflación del mes actual. Esto indica que los shocks pueden tener un efecto de corrección a medio plazo.

4. **MA(4) = -0.6538**

Este coeficiente negativo sugiere que un shock en la inflación cuatro meses antes (t-4) está asociado con una disminución del 65.38% en la inflación del mes actual. Esto muestra una corrección significativa en la inflación debido a shocks pasados.

Interpretación del Modelo ARIMA (2,0,1)

Este modelo tiene la forma ARIMA (p, d, q) donde:

- $p=2$ indica que el modelo incluye 2 términos autorregresivos (AR).
- $d=0$ indica que la serie de tiempo no ha sido diferenciada (es decir, ya es estacionaria).
- $q=1$ indica que el modelo incluye 1 término de media móvil (MA).

Coeficientes AR modelo ARIMA (2,0,1) (Autorregresivos)

1. **AR (1) = 0.7528**

Este coeficiente indica que un aumento en la inflación del mes anterior (t-1) está asociado con un aumento del 75.28% en la inflación del mes actual. Muestra una fuerte inercia en la inflación.

2. **AR (2) = -0.0679**

Un valor negativo pequeño sugiere que un aumento en la inflación dos meses antes (t-2) está asociado con una disminución del 6.79% en la inflación del mes actual. Indica una corrección menor y un efecto residual débil de los valores pasados.

Coeficiente MA modelo ARIMA (2,0,1) (Media Móvil)

1. **MA (1) = 0.9284**

Este coeficiente indica que un shock en la inflación del mes anterior ($t-1$) está asociado con un aumento del 92.84% en la inflación del mes actual. Esto sugiere que los shocks recientes tienen un efecto casi igual al del valor pasado de la inflación, mostrando una alta sensibilidad a los cambios inesperados.

Este modelo sugiere que la inflación en Argentina tiene una memoria relativamente corta (solo dos meses) y que los shocks imprevistos tienen una fuerte influencia en la determinación de la inflación mensual.

Interpretación económica

En 1989, la inflación mensual promedio fue del 46,5%. Este dato histórico destaca un período de hiperinflación en Argentina, lo que implica que la serie de tiempo de inflación ha experimentado variaciones extremas y episodios de alta volatilidad. Los coeficientes AR muestran cómo los valores pasados de la inflación afectan los valores presentes. Coeficientes positivos indican que aumentos en la inflación pasada llevan a aumentos en la inflación presente, mientras que coeficientes negativos indican correcciones o disminuciones. En el contexto de Argentina, esto refleja un comportamiento de inflación persistente con fluctuaciones cíclicas y oscilaciones en respuesta a variaciones pasadas.

Los coeficientes MA muestran cómo los shocks o errores pasados afectan los valores presentes. Coeficientes positivos sugieren que los shocks positivos llevan a aumentos en la inflación presente, mientras que coeficientes negativos sugieren una corrección. La alta magnitud de estos coeficientes en el contexto argentino sugiere que la inflación es altamente sensible a eventos imprevistos, lo cual es consistente con la historia económica de alta volatilidad del país.

Predicción

```
library(TSA)
```

```
## Warning: package 'TSA' was built under R version 4.3.3
```

```
## Registered S3 methods overwritten by 'TSA':
```

```
##   method      from
```

```
##   fitted.Arima forecast
```


```
##   plot.Arima   forecast
```

```
##  
## Attaching package: 'TSA'  
  
## The following objects are masked from 'package:stats':  
##  
##      acf, arima  
  
## The following object is masked from 'package:utils':  
##  
##      tar  
  
modeloarima<-auto.arima(deseasonal_inf, seasonal=FALSE)
```

##Podemos especificar el horizonte de pronóstico h periodos por delante para que se realicen las predicciones, y usar el modelo ajustado para generar dichas predicciones:

```
#prediccion para los proximos treinta meses con una confianza del 95%  
prediccion <- forecast(modeloarima, h=100, level= c(95))  
plot(prediccion)
```

Forecasts from ARIMA(5,1,4)



```
# Calcular las medidas de precisión del modelo
```

```
accuracy_measures <- accuracy(modeloarima)
```

```
# Imprimir las medidas de precisión
```

```
print(accuracy_measures)
```

```
##              ME      RMSE      MAE      MPE      MAPE      MA
SE
## Training set 0.001043776 0.1933381 0.08785958 0.01062971 14.62566 0.020232
22
##              ACF1
## Training set -0.02574648
```

Análisis del Gráfico y Predicción Económica

Comportamiento Histórico

El gráfico muestra una serie temporal de inflación con notables fluctuaciones y picos hasta el período 10 (1980 a 1990), seguido de una estabilización (1990 al 2000) . Estos picos pueden

representar períodos de alta inflación, posiblemente correlacionados con eventos económicos específicos en Argentina, como la crisis económica desencadenada en el Gobierno de Raúl Alfonsín, cambios en la política monetaria o fiscal, o shocks externos.

Predicción a Futuro

La línea azul en el gráfico representa la predicción futura de la inflación mensual. La predicción es relativamente estable, el rango de la predicción establece una inflación entre 5 y 10%, en comparación con las fluctuaciones históricas, lo que podría sugerir que el modelo espera una inflación controlada en el futuro cercano. El área sombreada en gris representa el intervalo de confianza del 95%, que se ensancha con el tiempo. Esto indica una mayor incertidumbre en las predicciones a largo plazo.

Interpretación Económica

Estabilidad Predicha: La predicción de una inflación más estable podría ser interpretada como un signo positivo, indicando que se esperan menores variaciones en la inflación mensual. Esto puede ser resultado de políticas económicas más efectivas o de un entorno económico más estable, en todo caso, el saneamiento de la política monetaria y la eliminación de monetización del déficit.

Riesgo de Incertidumbre: El ensanchamiento del intervalo de confianza sugiere que, aunque el modelo predice estabilidad, hay incertidumbre y riesgo de que la inflación pueda variar más de lo esperado, el intervalo va desde un -20% hasta un 35% de alta inflación mensual. Factores como cambios en las políticas económicas, eventos políticos, o shocks externos podrían afectar la inflación futura.

Impacto en la Política Económica: Las autoridades económicas pueden usar esta predicción para planificar y ajustar sus políticas. Si la predicción de estabilidad se mantiene, podrían centrarse en políticas de crecimiento y desarrollo económico. Sin embargo, deben estar preparados para ajustar las políticas si la inflación se desvía de la predicción.

Decisiones de Inversión: Los inversores podrían interpretar esta predicción como una señal de un entorno económico más predecible y podrían estar más dispuestos a invertir en el país. Sin embargo, deben tener en cuenta la incertidumbre reflejada en el intervalo de confianza.

El gráfico del modelo ARIMA (5,1,4) nos sugiere una predicción de estabilidad en la inflación mensual de Argentina, lo cual es un signo positivo para la economía. No obstante, el ensanchamiento del intervalo de confianza indica que hay incertidumbre y posibles riesgos que deben ser monitoreados. Las autoridades económicas y los inversores deben tener en cuenta estas predicciones y estar preparados para ajustar sus estrategias en respuesta a cambios en el entorno económico.

Validación

```
# Prueba de Ljung-Box
Box.test(datos.ts, lag = 20, type = "Ljung-Box")

##
## Box-Ljung test
##
## data:  datos.ts
## X-squared = 1509.4, df = 20, p-value < 2.2e-16

# Prueba de Shapiro-Wilk
shapiro.test(datos_decomp$random)

##
## Shapiro-Wilk normality test
##
## data:  datos_decomp$random
## W = 0.3872, p-value < 2.2e-16
```

Las pruebas de Ljung-Box y de Shapiro-Wilk son herramientas estadísticas utilizadas para evaluar la idoneidad de los modelos de series temporales y la normalidad de los residuos del modelo, respectivamente. A continuación, se describe qué nos indican estas pruebas en el contexto del modelo ARIMA (5,1,4):

Prueba de Ljung-Box

Objetivo:

- La prueba de Ljung-Box se utiliza para verificar la presencia de autocorrelación en los residuos de un modelo de serie temporal.

Hipótesis:

- **Hipótesis nula (H0):** Los residuos no están auto correlacionados (i.e., los residuos son independientes).
- **Hipótesis alternativa (H1):** Los residuos están auto correlacionados (i.e., hay dependencia en los residuos).

Resultados e Interpretación:

Un p-valor muy bajo (por ejemplo, $p\text{-value} < 2.2e-16$) indica que podemos rechazar la hipótesis nula y concluir que hay autocorrelación significativa en los residuos del modelo.

La presencia de autocorrelación en los residuos sugiere que el modelo ARIMA (5,1,4) no ha capturado toda la estructura de dependencia temporal en los datos. Esto podría implicar que el modelo no es completamente adecuado y que podría mejorarse, quizás considerando un modelo diferente o agregando términos adicionales.

Prueba de Shapiro-Wilk

Objetivo:

- La prueba de Shapiro-Wilk se utiliza para evaluar la normalidad de los residuos de un modelo de serie temporal.

Hipótesis:

- **Hipótesis nula (H0):** Los residuos siguen una distribución normal.
- **Hipótesis alternativa (H1):** Los residuos no siguen una distribución normal.

Resultados e Interpretación:

- Un p-valor muy bajo (por ejemplo, $p\text{-value} < 2.2e-16$) indica que podemos rechazar la hipótesis nula y concluir que los residuos no siguen una distribución normal.
- La no normalidad de los residuos sugiere que las suposiciones subyacentes del modelo ARIMA pueden no estar completamente satisfechas, lo que podría afectar la validez de las predicciones y los intervalos de confianza.

Conclusión de las pruebas

- **Prueba de Ljung-Box:** La presencia de autocorrelación en los residuos indica que el modelo ARIMA (5,1,4) puede no ser completamente adecuado y puede necesitar ajuste o cambio.
- **Prueba de Shapiro-Wilk:** La no normalidad de los residuos sugiere que las predicciones e inferencias basadas en el modelo ARIMA (5,1,4) pueden no ser totalmente confiables, ya que muchas técnicas de inferencia estadística asumen normalidad de los residuos.

Ambas pruebas sugieren que, aunque el modelo ARIMA (5,1,4) puede proporcionar una buena aproximación inicial, hay espacio para mejorar el modelo o considerar otros enfoques para capturar mejor la dinámica de la serie temporal y asegurar la precisión de las predicciones.

Resumen de la Interpretación

- **Error Medio (ME):** Muy cercano a 0, lo cual es positivo y sugiere que el modelo no está sesgado.
- **RMSE y MAE:** Relativamente bajos, lo cual indica que el modelo se ajusta bien a los datos.
- **MPE:** Bajo, indicando un buen rendimiento en términos de error porcentual medio.
- **MAPE:** Alto, sugiriendo posibles problemas con valores atípicos o un ajuste deficiente en ciertas partes de los datos.

- **MASE:** Menor que 1, indicando que el modelo es mejor que un modelo naive.
- **ACF1:** Muy cercano a 0, indicando que no hay autocorrelación significativa en los errores residuales.